你說：

做一份機器學習作業，要求從 Kaggle 找一個有 10 到 20 個特徵的公開資料集，
用多元線性回歸（Multiple Linear Regression）做預測，並按照 CRISP-DM 流程完成分析，
還要做特徵選擇和模型評估。請推薦 3 到 5 個適合的 Kaggle 資料集，
說明各自的特徵數、目標變數、優缺點，並告訴我哪一個最適合展示線性回歸。

ChatGPT 說：

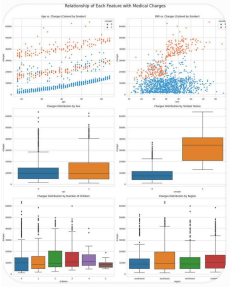
我會建議你優先選擇**數值型特徵夠多、目標變數是連續數值、資料清理不會太複雜，而且能清楚解釋回歸係數**的 Kaggle 資料集。

因為這份作業不只是訓練一個 Multiple Linear Regression（多元線性回歸）模型，還要按照 CRISP-DM 完成分析、做特徵選擇與模型評估，所以資料集最好能讓你展示完整的分析過程，而不只是追求預測準確率。

以下我會比較 5 個候選資料集，並區分「原始欄位數」與「實際用來建模的特徵數」——這兩者不一定相同。

一、推薦的 5 個 Kaggle 資料集

以下特徵數以適合本次作業的建模方式估算；正式下載後仍應檢查欄位、缺失值與資料版本。第 1、2 個最符合回歸分析教學需求。



1. Medical Cost Personal Datasets

最推薦

資料來源：Kaggle Medical Cost Personal Datasets

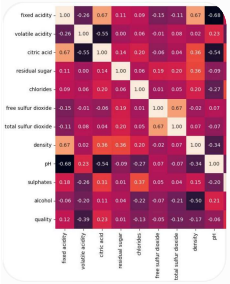
- **資料量：** 1,338 筆
- **原始欄位：** 7 欄
- **原始輸入特徵：** 6 個
- **目標變數：** `charges`（醫療保險費用）

優點： 問題直觀、資料量適中，能討論年齡、BMI、吸菸狀態與費用的關係；很適合做殘差分析、特徵選擇與迴歸係數解釋。

缺點： 有類別型變數，需要編碼；吸菸與費用的關係可能呈現非線性或交互作用，線性模型未必能充分捕捉。

注意：原始只有 6 個輸入特徵，若老師要求原始資料就必須有 10–20 個特徵，這個不符合；若允許特徵工程，才適合納入考慮。 kaggle.com +1

前往 Kaggle 資料集 ↗



2. UCI Wine Quality Dataset

最符合原始特徵數

資料來源：UCI Wine Quality Dataset

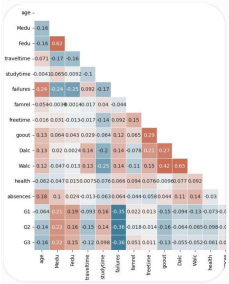
- **資料量：** 白酒資料約 4,898 筆；紅酒資料約 1,599 筆
- **輸入特徵：** 11 個理化特徵（白酒或紅酒分開使用）
- **目標變數：** `quality`（品質評分）

優點： 11 個數值型特徵，不需大量類別編碼；可以分析酒精濃度、酸度、密度等變數與品質評分的關係，適合相關係數、特徵選擇及殘差視覺化。

缺點： 品質評分是離散的有序分數，不是完全連續的測量值；特徵與品質之間可能存在非線性，而且模型的 R^2 不一定很高。

原始資料的輸入特徵數正好符合 10–20 個的要求。 Kaggle +1

前往 Kaggle 資料集 ↗



3. Student Performance Data Set

資料來源：Student Performance Data Set

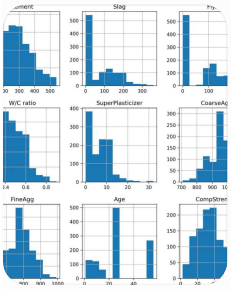
- **資料量：** 數學約 395 筆、葡萄牙語約 649 筆
- **原始欄位：** 33 個左右，視版本而定
- **建模特徵：** 可自行挑選 10–20 個
- **目標變數：** `G3`（期末成績）

優點： 可以研究讀書時間、缺課、家庭背景與成績的關聯；很適合展示特徵選擇前後的差異。

缺點： 有不少類別型欄位，需要編碼；若納入 `G1`、`G2`（前兩次成績），可能使預測看起來過於容易，因此應說明預測情境。

官方資料說明也特別指出，`G1`、`G2` 與 `G3` 高度相關。 kaggle.com

前往 Kaggle 資料集 ↗



4. Concrete Compressive Strength

資料來源：Concrete Compressive Strength Dataset

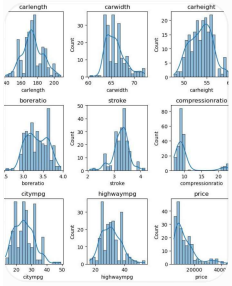
- **資料量：** 常見版本 1,030 筆
- **輸入特徵：** 8 個數值型特徵
- **目標變數：** 混凝土抗壓強度（MPa）

優點： 幾乎不需類別編碼，材料配比與強度的關係容易解釋；可以分析特徵相關性、係數與預測誤差。

缺點： 原始只有 8 個輸入特徵，不符合嚴格的 10–20 個原始特徵要求；若老師要求欄位數必須符合，就不應選它。

資料特性與無缺失值資訊可參考 Kaggle 上的資料說明。 kaggle.com

前往 Kaggle 資料集 ↗



5. Used Car Price Prediction Dataset

資料來源：Used Car Price Prediction Dataset

- **資料量：** 約 4,009 筆
- **原始欄位：** 約 13 欄，依版本不同
- **建模特徵：** 可選擇 10–12 個合適欄位
- **目標變數：** `Price`（二手車價格）

優點： 預測價格的應用情境明確；可以分析車齡、里程數、引擎規格與價格的關係。

缺點： 品牌、車型、燃料與變速箱等欄位需要編碼，可能增加特徵數；價格通常有離群值與非線性關係，線性回歸可能不是最佳模型。

此資料集的部分版本含混合型態欄位，實際欄位數須以選定版本為準。 Kaggle +1

前往 Kaggle 資料集 ↗

二、哪個最適合你的作業？

如果老師明確要求「從 Kaggle 找一個具有 10–20 個特徵的公開資料集」，我會把 **Wine Quality 放在第一順位**。

比較項目	Wine Quality	Student Performance	Used Car
原始輸入特徵符合 10–20 個	✅ 11 個	✅ 可挑選	✅ 依版本
需要類別編碼	少	多	多
特徵選擇容易展示	很適合	很適合	適合
迴歸係數容易解釋	很適合	適合	適合
資料清理難度	低	中	中至高
符合本次作業的整體程度	最高	次高	次高

三、如何按照 CRISP-DM 完成分析？

以 Wine Quality 為例，你可以直接按照以下六個階段安排報告。

1. Business Understanding — 商業理解

定義問題：根據葡萄酒的理化性質，預測品質評分 `quality`。

研究問題：哪些理化特徵與品質評分有關？使用全部 11 個特徵是否比選擇部分特徵更好？

2. Data Understanding — 資料理解

- 檢查資料筆數、欄位型態與缺失值。
- 查看 `quality` 的分布。
- 畫相關係數熱圖、直方圖與散佈圖。
- 檢查異常值與特徵之間的高度相關性。

3. Data Preparation — 資料準備

- 移除重複資料（若存在且有合理依據）。
- 分離輸入 X 與目標 y。
- 切分訓練集與測試集，例如 80:20。
- 確保特徵選擇只使用訓練資料，避免資料洩漏。

---

4. Modeling — 模型建立

建立兩個多元線性回歸模型：

- **Model A：** 使用全部 11 個輸入特徵。
- **Model B：** 使用特徵選擇方法挑選出的子集。

比較兩個模型，觀察特徵減少後，預測能力是否改變。

---

5. Evaluation — 模型評估

使用測試集計算 R^2、RMSE 與 MAE，並檢查殘差圖。

不要只比較訓練集的分數；模型應該在沒有參與訓練的資料上接受評估。

---

6. Deployment — 部署與應用

本次作業不一定需要真的部署模型。可以展示一筆新資料的預測結果，解釋模型的用途、限制與未來改善方向。

四、特徵選擇怎麼做才有分析價值？

建議使用兩種方法，比較結果，而不是只挑選與目標相關性最高的幾個欄位。

方法	原理	作業中可以展示什麼
Pearson 相關係數	衡量特徵與目標的線性相關程度	特徵相關性排序
SelectKBest	以統計分數選出前 k 個特徵	例如比較前 5 個與全部 11 個特徵
RFE	反覆訓練模型並移除較不重要的特徵	特徵數量與模型表現的關係

我的建議： 使用 Pearson 相關係數作為探索分析，再用 RFE 或 SelectKBest 進行正式特徵選擇。所有選擇程序都應限制在訓練集內，並在相同測試集上比較模型。

五、模型評估應該呈現哪些指標？

R^2：決定係數

表示模型在測試資料上解釋目標變數變異的程度。越接近 1 通常越好，但測試集上的 R^2 也可能小於 0。

RMSE：均方根誤差

對較大的預測誤差懲罰較重，單位與目標變數相同。越低越好。

MAE：平均絕對誤差

表示預測值與實際值平均相差多少，容易解釋。越低越好。

最終可以整理成一張表：

模型	特徵數	Test R^2	Test RMSE	Test MAE
Model A：全部特徵	11	實驗後填入	實驗後填入	實驗後填入
Model B：特徵選擇	依選擇結果	實驗後填入	實驗後填入	實驗後填入

不要預先假設特徵選擇一定會提升準確度。即使分數略微下降，若模型更簡單、解釋性更好，也能成為有價值的分析結果。

最後的選擇建議

我最推薦你選 Wine Quality Dataset。 它有剛好 11 個數值型輸入特徵，不必為了符合欄位數要求而人工新增特徵，也能完整展示 CRISP-DM、特徵選擇、多元線性回歸及模型評估。

但有一點值得在報告中主動說明：葡萄酒品質評分是有序的離散分數，因此線性回歸是本次作業指定的預測方法，不代表它一定是最適合這類資料的所有方法。這種對模型假設與限制的反思，反而能讓你的報告更完整。

你說：

請詳細說明 CRISP-DM 的六個階段，每個階段在一份「多元線性回歸」報告中
具體應該寫哪些內容？另外請告訴我，學生在寫 CRISP-DM 報告時最常遺漏哪些項目？

ChatGPT 說：

CRISP-DM 可以理解成一套**從「定義問題」到「建立模型、驗證結果，再思考如何應用」的資料分析流程**。對你的多元線性回歸作業來說，它不是把六個階段的名稱列出來就好，而是要讓讀者看得懂：為什麼選這份資料、如何處理資料、為什麼選這些特徵、模型表現如何，以及結論是否有證據支持。

我以下會以你前面考慮的 **Wine Quality Dataset（葡萄酒品質資料集）** 作為貫穿全篇的範例。這樣你可以直接將內容轉化成報告章節；實際數據、圖表與模型結果則要等你執行分析後再填入。

一、CRISP-DM 六個階段總覽

01 **商業理解（Business Understanding）**
我要解決什麼問題？為什麼值得分析？

02 **資料理解（Data Understanding）**
資料有哪些特徵？品質如何？能回答問題嗎？

03 **資料準備（Data Preparation）**
如何清理、轉換及切分資料？

04 **模型建立（Modeling）**
如何建立多元線性回歸及選擇特徵？

05 **模型評估（Evaluation）**
模型是否有效？結果是否可信？

06 **部署與應用（Deployment）**
如何使用模型？有哪些限制與後續方向？

實際分析不是只能單向進行。如果模型評估發現效果不佳，可以回到資料理解、資料準備或模型建立階段重新調整。

二、第一階段：Business Understanding（商業理解）

這一階段要回答什麼？

為什麼要做這個預測？你希望透過分析得到什麼？

這裡不是先介紹 Python 程式，也不是先畫相關係數熱圖，而是先定義研究目的與成功標準。

1. 報告應該寫哪些內容？

報告項目	具體應寫的內容
研究背景	為什麼葡萄酒品質預測值得研究
問題定義	能否利用葡萄酒的理化性質預測品質評分
分析目標	建立多元線性回歸模型，預測 `quality`
研究問題	哪些特徵與品質較有關聯？特徵選擇能否改善模型？
成功標準	使用測試集的 R^2、RMSE、MAE 評估預測能力
分析範圍	指定使用白酒或紅酒資料，以及模型使用的特徵範圍

2. 可以直接放進報告的範例

寫作

1. Business Understanding（商業理解）

1.1 研究背景

葡萄酒的品質可能與酒精濃度、酸度、密度及其他理化性質有關。本研究希望透過資料分析，了解這些理化特徵與葡萄酒品質評分之間的關係，並建立可用於預測品質評分的統計模型。

1.2 研究目標

本研究採用 Kaggle 公開的 Wine Quality Dataset，以多元線性回歸（Multiple Linear Regression）建立預測模型，並比較使用全部輸入特徵與經過特徵選擇後的模型表現。

1.3 研究問題

1. 哪些理化特徵與葡萄酒品質評分具有較明顯的線性關聯？
2. 使用特徵選擇方法，能否在減少輸入特徵的同時維持良好的預測表現？
3. 多元線性回歸在此資料集上的預測能力與主要限制為何？

1.4 成功標準

本研究以測試集的決定係數（R^2）、均方根誤差（RMSE）及平均絕對誤差（MAE）評估模型，並比較特徵選擇前後的預測結果。模型表現的優劣將依實際實驗結果判定，不預先假設特徵選擇一定能提升準確度。

3. 這一階段最常見的錯誤

- 只寫「我要用線性回歸預測葡萄酒品質」，卻沒有研究問題。
- 一開始就說某個特徵最重要，但尚未分析資料。
- 沒有定義成功標準，只在最後宣稱模型效果很好。
- 把預測關係直接寫成因果關係。例如，發現某特徵與品質有關，不代表它一定造成品質變化。

完成這一階段的檢查點： 讀者即使不看你的程式碼，也能理解你要預測什麼、為什麼做，以及如何判斷成果。

三、第二階段：Data Understanding（資料理解）

這一階段要回答什麼？

你拿到的資料是什麼？資料品質如何？這份資料適不適合你的研究問題？

這階段的重點是探索資料，而不是急著訓練模型。你要用數據、統計摘要與視覺化，證明自己理解資料的特性。

1. 報告應該寫哪些內容？

A. 資料來源與基本資訊

- Kaggle 資料集名稱、網址與下載日期。
- 資料集版本、原始檔案名稱。
- 資料筆數、欄位數及各欄位的意義。
- 指定使用紅酒或白酒資料，並說明理由。

B. 欄位與資料型態

- 哪些是輸入特徵 X？
- 哪一欄是目標變數 y？
- 欄位是否為數值型、類別型或文字型？
- 每個特徵的單位、意義與合理範圍。

C. 描述性統計與視覺化

- 平均數、標準差、中位數、最小值、最大值。
- 目標變數的分布。
- 特徵的直方圖、箱型圖。
- 特徵與目標變數的散佈圖、相關係數熱圖。

D. 初步資料品質檢查

- 缺失值數量及比例。
- 重複資料。
- 異常值或不合理數值。
- 特徵之間的高度相關性。
- 目標變數是否集中於少數分數。

2. 建議至少製作哪些圖表？

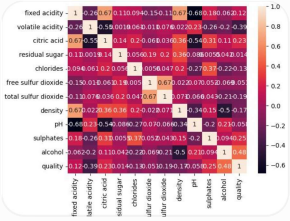


圖 1：相關係數熱圖

用來觀察各特徵與 `quality` 的相關方向及程度，也能發現輸入特徵彼此高度相關的情況。

報告要解釋重要觀察，不是只放圖。例如：某特徵與品質的相關係數較高，但仍需透過模型及測試集確認其預測價值。

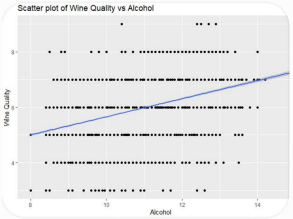


圖 2：特徵與目標的散佈圖

例如 `alcohol` 與 `quality`。用來觀察線性趨勢是否明顯、是否有群聚、離群值或曲線型態。

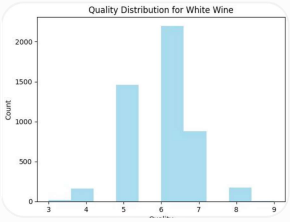


圖 3：目標變數分布

查看各品質評分出現的頻率。若分數集中在少數幾個值，可能影響模型評估及解讀。

上面圖片是圖表類型的示意參考，並非你所選資料集的實際分析結果。正式報告應使用程式從下載的資料產生圖表。

3. 這一階段最容易被忽略的地方

只展示圖表，沒有解釋圖表的發現。

例如，不應只寫：

> 從相關係數熱圖可以看到各變數的相關性。

應該進一步寫成：

> 本研究利用相關係數熱圖檢查輸入特徵與品質評分的線性關聯，並確認部分輸入特徵是否具有高度相關性。這些結果將作為後續特徵選擇與多元線性回歸診斷的參考，但不直接代表因果關係。

最後，請把實際觀察到的特徵名稱、相關係數或分布特性補上。

完成這一階段的檢查點： 你已經知道資料有多少筆、欄位代表什麼、資料品質如何，以及哪些現象值得進一步研究。

四、第三階段：Data Preparation（資料準備）

這一階段要回答什麼？

如何把原始資料整理成能夠正確訓練及評估模型的形式？

這是學生最容易低估的階段。即使模型使用正確，只要資料切分錯誤、發生資料洩漏，或是前處理方式不合理，最終結果仍可能不可信。

1. 報告應該寫哪些內容？

項目	具體應寫的內容
資料篩選	為何選用紅酒或白酒、是否排除特定欄位
缺失值處理	是否有缺失值、採取何種處理及原因
重複資料	是否存在重複列、如何處理
異常值	如何辨識、是否保留、排除的依據
特徵與目標分離	說明 X 與 y 的欄位
資料切分	訓練集、測試集比例及隨機種子
特徵轉換	是否需要標準化、編碼或其他轉換
特徵選擇準備	特徵選擇器如何訓練，如何避免測試集資訊洩漏

2. 建議的處理順序

原始 Kaggle 資料

↓

檢查欄位、缺失值、重複資料與異常值

↓

分離輸入特徵 X 與目標變數 y

↓

切分訓練集與測試集（例如 80%：20%）

↓

訓練集	測試集
擬合前處理、選擇特徵、訓練模型	保留到最後，評估泛化能力

3. 什麼是資料洩漏？為什麼特別重要？

假設你想用相關係數挑選 5 個最重要的特徵。

錯誤做法是先拿全部資料（包含測試集）計算相關係數，再切分訓練集與測試集。因為特徵選擇過程已經使用測試資料的資訊，最終評估可能過度樂觀。

正確做法是：

1. 先切分訓練集與測試集。
2. 只在訓練集上計算特徵分數並選出特徵。
3. 使用選出的特徵訓練模型。
4. 對測試集套用同一組特徵，最後評估。

如果還要用交叉驗證調整特徵數量或其他設定，則應把特徵選擇放在交叉驗證的每個訓練折內，常見做法是使用 Scikit-learn 的 `Pipeline`。

4. 線性回歸是否需要標準化？

普通最小平方法的多元線性回歸通常不要求輸入特徵一定要標準化，因為改變特徵尺度不會改變相同模型的理論預測能力（在數值計算穩定、模型設定一致的前提下）。

但標準化仍可能有幫助：

- 讓不同尺度的迴歸係數較容易比較。
- 方便某些以係數大小為基礎的特徵選擇方法。
- 對 Ridge、Lasso 等正則化模型尤其重要。

若你使用標準化，應只用訓練集估計平均數與標準差，再套用至測試集。

5. 這一階段最常見的遺漏

- 沒有說明為什麼刪除某些資料或欄位。
- 只說「資料已清理」，卻沒有列出缺失值、重複值的實際檢查結果。
- 沒有交代訓練集與測試集比例。
- 在分割資料之前，使用全部資料進行特徵選擇或標準化。
- 沒有固定 `random_state`，導致實驗難以重現。
- 為了讓結果更好而隨意刪除離群值，卻沒有合理依據。

完成這一階段的檢查點： 別人能夠依照你的報告，理解原始資料如何一步步轉變成模型的輸入，而且不會因資料洩漏而高估模型效果。

五、第四階段：Modeling（模型建立）

這一階段要回答什麼？

你如何建立多元線性回歸模型？為什麼使用這些特徵？模型是否符合線性回歸的基本假設？

這是整份作業的核心技術階段。你不只要呼叫 `LinearRegression()`，還要說明模型原理、特徵選擇方法、實驗設計，以及如何檢查模型是否合理。

1. 說明多元線性回歸的原理

多元線性回歸使用多個輸入特徵，預測一個連續型目標變數。其模型可以表示為：

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

其中：

- $\hat{y}$：預測的葡萄酒品質評分。
- β_0：截距。
- $x_1, \ldots, x_p$：輸入特徵，例如酒精濃度、密度。
- $\beta_1, \ldots, \beta_p$：各特徵的迴歸係數。
- p：輸入特徵數量。

一般最小平方法會尋找一組係數，使訓練資料的殘差平方和最小：

$$\min_{\beta_0,\ldots,\beta_p} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

這代表模型會盡量減少訓練資料中「實際值與預測值之間的平方誤差總和」。

2. 特徵選擇要如何寫？

建議至少比較兩種模型：

Model A：完整特徵模型 Baseline

使用全部 11 個輸入特徵建立多元線性回歸。

目的： 建立基準，作為後續特徵選擇模型的比較對象。

Model B：特徵選擇模型 比較模型

使用訓練集中的統計分數或 RFE，選出較少的特徵，再建立相同類型的回歸模型。

目的： 檢驗減少特徵後，預測效能與模型簡潔性有何變化。

在報告中，必須交代：

1. 使用哪一種特徵選擇方法。
2. 為什麼選擇這個方法。
3. 如何決定保留幾個特徵。
4. 最終選出的特徵有哪些。
5. 特徵選擇前後的模型評估結果。

例如，如果使用 RFE 選出 5 個特徵，就要列出這 5 個特徵的名稱，而不能只寫「使用 RFE 進行特徵選擇」。

另外，Pearson 相關係數只能衡量單一特徵與目標的線性關係，不能完全反映該特徵在其他變數已經納入模型後的額外貢獻。

3. 模型建立階段應呈現的結果

項目	報告應呈現的內容
模型設定	使用的回歸演算法與主要參數
特徵選擇	方法、選擇依據、最終特徵
模型訓練	訓練資料數量、輸入維度
係數分析	主要迴歸係數的方向及意義
模型診斷	殘差圖、線性關係、共線性等
實驗設計	如何確保模型 A 與模型 B 的比較公平

4. 迴歸係數應該如何解釋？

假設某次實驗得到某個特徵的係數為正值，在其他輸入特徵固定時，該特徵增加通常對應較高的預測值。

但必須注意：

- 係數的正負方向與大小，都應根據實際模型結果解釋。

- 不同特徵的單位不同，不能直接只靠原始係數大小判斷重要性。
- 高度相關的輸入特徵可能使係數不穩定。
- 係數代表模型中的條件關聯，不直接證明因果關係。

5. 線性回歸的假設也要檢查

學生經常只報告 R^2，卻忽略模型本身是否合理。

線性關係

輸入特徵與目標之間的關係是否能以線性形式合理描述？可搭配散佈圖與殘差圖觀察。

殘差的型態與變異

殘差對預測值的圖若呈現明顯曲線或漏斗形，可能表示線性假設或等變異性假設有問題。

多重共線性

可以使用相關係數矩陣或 VIF 檢查輸入特徵間的高度線性關聯。共線性不一定讓預測失效，但可能讓係數解釋變得不穩定。

殘差的常態性與獨立性

若要進行傳統迴歸係數的顯著性檢定與信賴區間推論，這些假設尤其重要。常態性不是計算一般最小平方法預測值的必要條件；獨立性則要依資料如何產生來判斷。

6. 這一階段最常見的遺漏

- 沒有說明為什麼選擇多元線性回歸。
- 沒有交代最終使用了哪些特徵。
- 只比較模型分數，沒有說明特徵選擇方法。
- 把特徵與目標的相關係數直接當成迴歸係數。
- 只展示模型程式碼，沒有解釋模型結果。
- 沒有進行殘差分析或檢查多重共線性。

完成這一階段的檢查點： 讀者知道模型如何建立、特徵如何挑選、係數代表什麼，以及模型的哪些假設值得注意。

六、第五階段：Evaluation（模型評估）

這一階段要回答什麼？

模型是否真的能預測未知資料？模型的表現是否達到第一階段定義的目標？

這裡要注意：Modeling 是建立模型，Evaluation 則是判斷模型是否足夠好，以及結果是否值得相信。兩者相關，但不能混為一談。

1. 必須報告的三個指標

決定係數（R^2）

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

衡量模型相對於以測試集實際平均值作為預測基準，改善了多少平方誤差。

越接近 1 通常越好；若測試集的 R^2 小於 0，代表模型甚至比該基準更差。

均方根誤差（RMSE）

$$RMSE = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}$$

對較大的預測誤差較敏感。單位與目標變數相同；若目標是品質分數，RMSE 也以分數表示。

平均絕對誤差（MAE）

$$MAE = \frac{1}{n}\sum_i |y_i - \hat{y}_i|$$

表示預測值與實際值的平均絕對差距。比 RMSE 更容易用一般語言解釋。

2. 應該如何公平比較兩個模型？

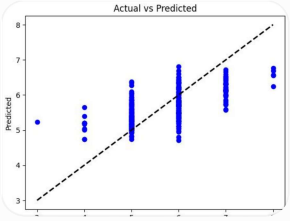
比較項目	Model A	Model B
輸入特徵數	全部特徵	選擇後的特徵
測試資料	相同測試集	相同測試集
R^2	實驗後填入	實驗後填入
RMSE	實驗後填入	實驗後填入
MAE	實驗後填入	實驗後填入
解釋性	參考基準	評估是否更簡潔

比較時應注意：

- 不能用 Model A 的訓練集分數，與 Model B 的測試集分數直接比較。
- 不能因為特徵數變少，就認定模型一定比較好。
- 如果有調整特徵數或模型設定，應利用訓練資料內的交叉驗證進行選擇，並保留測試集作最終評估。
- R^2 較高不代表所有預測都準確，還要搭配 RMSE、MAE 與殘差圖。

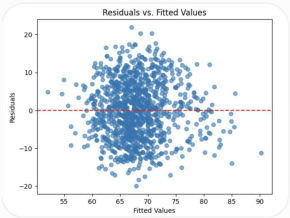
3. 還要檢查預測結果

建議至少製作兩張圖：



實際值 vs. 預測值

如果預測理想，資料點會較靠近 $y = x$ 的參考線。對 Wine Quality 而言，也要留意模型是否容易低估高品質樣本，或高估低品質樣本。



殘差 vs. 預測值

檢查殘差是否大致圍繞零分布、有沒有明顯曲線、漏斗形或其他系統性模式。

這些同樣是示意圖類型。正式報告要以你訓練出的模型生成實際圖表，不要將網路上的示意圖當作自己的實驗結果。

4. Evaluation 與 Modeling 有什麼不同？

這個區分是 CRISP-DM 報告常見的失分點。

- **Modeling：** 我使用 RFE 選出 5 個特徵，並訓練多元線性回歸。
- **Evaluation：** 使用保留的測試集比較兩個模型，發現選擇後的模型在特徵數減少的情況下，測試集 RMSE 如何變化；再搭配殘差圖判斷模型是否存在系統性誤差。

前者描述「做了什麼」，後者描述「結果如何，以及結果代表什麼」。

5. 這一階段最常見的遺漏

- 只報告 R^2，沒有 RMSE 與 MAE。
- 只報告訓練集成績，沒有測試集評估。
- 沒有比較特徵選擇前後的模型。
- 看到指標就宣布模型成功，沒有回到研究目標判斷。
- 沒有討論模型的限制、誤差模式及可能的改善方向。

完成這一階段的檢查點： 你能用實驗證據說明模型表現，而不是只憑主觀判斷說它「很好」。

七、第六階段：Deployment（部署與應用）

這一階段要回答什麼？

如果模型已經訓練完成，接下來可以怎麼使用？它適合什麼情境，又有哪些限制？

CRISP-DM 的 Deployment 不代表一定要做成網站、手機 App 或雲端服務。對一般機器學習課程作業而言，提出可行的應用方式、展示預測範例，並討論模型限制，通常就能呈現這個階段的核心概念。

1. 報告應該寫哪些內容？

項目	具體應寫的內容
應用情境	模型可以用來做什麼？
預測示範	輸入一筆葡萄酒理化特徵，展示模型預測結果
使用限制	預測是否可靠、適用範圍為何
後續改善	未來可以改善哪些資料或模型問題
重現性	如何重新載入模型並產生預測

2. 以 Wine Quality 為例

你可以設計一個簡單的預測流程：



輸出預測品質評分

將預測值與適用的品質評分範圍對照

實作上，你可以使用 `joblib` 儲存模型，再用一筆新資料測試預測流程。若使用標準化或特徵選擇器，也應一起儲存整個 Pipeline，避免新資料套用不同的轉換方式。

3. 可以直接放進報告的範例

寫作

6. Deployment（部署與應用）

6.1 應用情境

本研究建立的多元線性回歸模型，可作為根據葡萄酒理化特徵估計品質評分的初步分析工具。使用者輸入符合模型所需欄位的理化測量值後，即可取得模型預測的品質評分。

6.2 模型使用方式

模型完成訓練與評估後，可將模型及必要的資料前處理流程儲存，以便後續載入並預測新資料。預測時必須確保輸入特徵的名稱、順序及轉換方式與訓練階段一致。

6.3 模型限制

本模型以線性關係描述理化特徵與品質評分之間的關聯，可能無法充分捕捉非線性關係及特徵間的交互作用。此外，模型的預測表現受到資料分布、樣本品質及資料來源限制，不能直接視為專業品酒評估或實際品質檢驗的替代品。

6.4 未來改善方向

未來可考慮蒐集更多樣化的樣本、檢驗不同特徵選擇方法、進一步改善模型診斷，並與其他回歸方法比較，以了解不同模型在預測效能與解釋性方面的差異。

4. 這一階段最常見的遺漏

- 完全沒有提到模型如何被使用。
- 把「模型訓練完成」當成部署。

- 沒有說明新資料的輸入格式。
- 忽略模型只適用於與訓練資料具有一定相似性的資料。
- 提出未經實驗驗證的改善效果，例如直接宣稱換成其他模型就一定更準。

完成這一階段的檢查點： 讀者知道模型能做什麼、如何使用，以及什麼情況下不應過度相信它。

八、學生寫 CRISP-DM 報告最常遺漏的項目

這裡特別整理成一份可以在繳交前逐項檢查的清單。除了每階段的內容不足，還有幾個跨階段的問題，尤其容易影響機器學習作業的品質。

繳交前檢查清單

0/20 已完成

1. 研究規劃與資料來源

- ◯ 有寫清楚研究問題，而不只是模型名稱
- ◯ 提供 Kaggle 資料集網址與實際使用的版本
- ◯ 清楚區分輸入特徵數、目標欄位與原始欄位數
- ◯ 事先定義評估指標與模型比較方式

2. 資料理解與準備

- ◯ 提供缺失值、重複資料及異常值檢查結果
- ◯ 使用描述性統計及有意義的圖表
- ◯ 說明每個資料清理決策的原因
- ◯ 交代訓練集、測試集比例與 random_state
- ◯ 先切分資料，再在訓練集內進行特徵選擇及擬合前處理

3. 模型建立與特徵選擇

- ◯ 解釋多元線性回歸的原理及使用理由
- ◯ 明確記錄特徵選擇方法及最終保留的特徵
- ◯ 比較完整特徵模型與選擇後模型
- ◯ 解釋主要迴歸係數，而不是只貼程式碼

- ◯ 檢查殘差、線性假設及多重共線性

4. 模型評估與結論

- ◯ 同時報告測試集 R^2、RMSE 與 MAE
- ◯ 使用相同的測試集公平比較模型
- ◯ 提供實際值與預測值圖、殘差圖
- ◯ 根據實際結果回答第一階段的研究問題
- ◯ 說明模型限制與未來改善方向
- ◯ 提供可重現的程式碼、套件與重要參數

複製檢查清單

九、另外三個容易混淆的觀念

1. Data Understanding 不等於 Data Preparation

- Data Understanding：檢查並理解資料，例如發現某些特徵高度相關。
- Data Preparation：根據檢查結果決定如何處理，例如保留、轉換或移除特徵。

前者是探索與診斷，後者是實際整理資料。

2. Modeling 不等於 Evaluation

- Modeling：建立模型、選擇特徵、訓練模型。
- Evaluation：利用未參與模型選擇的資料評估效果，檢查模型限制，並判斷是否達成目標。

不要把全部內容都塞進「模型訓練」章節。

3. CRISP-DM 不只是六個章節標題

真正重要的是每個階段之間有邏輯關聯。

例如：

- 第一階段提出「特徵選擇能否改善模型」。
- 第二階段發現部分特徵與品質的關係較弱，或彼此高度相關。
- 第三階段設計無資料洩漏的特徵選擇流程。
- 第四階段建立完整模型及特徵選擇模型。
- 第五階段使用測試集比較兩者。
- 第六階段根據實驗結果說明模型是否適合實際應用。

這才是完整的 CRISP-DM 分析，而不是單純按照六個標題填文字。

十、我建議你的報告採用這個章節架構

如果作業沒有規定固定格式，可以使用以下目錄：

封面、摘要

第 1 章　研究背景與目標（Business Understanding）

第 2 章　資料來源與探索性分析（Data Understanding）

第 3 章　資料清理與前處理（Data Preparation）

第 4 章　多元線性回歸與特徵選擇（Modeling）

第 5 章　模型評估與結果討論（Evaluation）

第 6 章　應用方式、限制與未來工作（Deployment）

參考資料、附錄（程式碼或補充圖表）

最後提醒： 不要在尚未執行實驗前，就先寫出「某特徵最重要」「特徵選擇使模型準確率提升」等結論。你可以先把研究問題、方法與實驗設計寫好，等跑完程式後再根據實際數值完成結果與討論。

對這份作業而言，最能展現你理解機器學習的地方，不是程式碼有多長，而是你能否清楚解釋**為什麼這樣處理資料、為什麼這樣選特徵，以及模型的結果究竟能支持什麼結論**。

你說：

我的資料集有 20 個數值特徵，我發現這 20 個特徵的「逐列加總（row sum）」
和目標變數的相關係數高達 0.91，但每個單一特徵的相關係數只有 0.2 左右。
我應該把這個 row sum 當成一個新特徵加進「線性回歸」模型嗎？請說明理由。

ChatGPT 說：

我的建議是：**可以把 row sum 當成候選特徵進行實驗，但不要只因為它與目標變數的相關係數高達 0.91，就直接認定應該加入模型。** 你需要先確認這個高相關的來源，再比較加入前後的測試集表現。

你觀察到的現象其實很值得分析：20 個特徵各自與目標的相關係數只有約 0.2，但把它們加總後，相關係數卻達到 0.91。這並不矛盾。

一、為什麼 row sum 的相關係數可能很高？

假設你的 20 個特徵為：

$$X_1, X_2, \ldots, X_{20}$$

你新增的特徵是：

$$S = \sum_{j=1}^{20} X_j$$

而目標變數為 Y。

相關係數衡量的是兩個變數之間的線性關聯。即使每個 X_j 與 Y 的個別相關係數都不高，它們加總後仍可能形成與 Y 高度相關的綜合指標。

例如，假設每個特徵都包含一些獨立的測量雜訊，但它們都部分反映同一個潛在因素。個別特徵受到雜訊影響，相關係數不高；加總後，部分雜訊可能互相抵銷，而共同的訊號則累積起來。

不過，這只是其中一種可能的解釋。你還需要確認是否存在以下情況：

- 20 個特徵其實共同反映某個總量或整體程度。
- 特徵之間具有高度相關性。
- 目標變數本身就是由這些特徵計算而來，或與它們存在直接的數學關係。
- 資料中有共同的尺度、基準值或其他結構性因素。

二、為什麼不能只看 0.91 就決定加入？

1. 高相關不代表能帶來額外的預測價值

假設原本的多元線性回歸模型是：

$$\hat{Y} = \beta_0 + \sum_{j=1}^{20} \beta_j X_j$$

現在新增 row sum：

$$\hat{Y} = \beta_0 + \sum_{j=1}^{20} \beta_j X_j + \gamma S$$

由於 S 本來就是 20 個特徵的線性組合，因此：

$$S = X_1 + X_2 + \cdots + X_{20}$$

把它代回模型後：

$$\hat{Y} = \beta_0 + \sum_{j=1}^{20} (\beta_j + \gamma) X_j$$

這個結果非常重要：**如果模型已經包含全部 20 個原始特徵，那麼新增 row sum 不會擴大模型原本能表示的線性預測函數範圍。**

對一般最小平方法（OLS）而言，只要使用相同的訓練資料，加入這個精確的線性組合不會改善理論上的最佳訓練集殘差平方和。

而且，如果 20 個原始特徵全部保留，row sum 會與它們產生完全的線性依賴，導致設計矩陣不滿秩。這會讓迴歸係數無法唯一識別，雖然某些軟體仍能透過廣義逆計算出預測結果。

2. 那為什麼 row sum 仍可能有用？

因為它可能在以下情況帶來價值：

- **你先選擇部分特徵，再加入 row sum。** 它可能補充被刪除特徵的綜合資訊。
- **你使用 Ridge、Lasso 等正則化模型。** 加入 row sum 會改變模型的參數化方式與懲罰效果，即使沒有增加線性函數空間，也可能影響泛化表現。
- **你希望建立更簡潔、容易解釋的模型。** 若 row sum 有明確的領域意義，可以考慮用它取代部分原始特徵，但需要評估資訊損失。

換句話說，row sum 的價值可能在於「如何組織或限制模型的資訊」，而不是它創造了新的獨立資訊。

三、我建議你做的實驗

不要只比較相關係數，請至少比較以下三種模型。

模型	輸入特徵	要回答的問題

Model A	全部 20 個原始特徵	基準模型的預測能力如何？
Model B	20 個原始特徵 + row sum	檢查線性依賴及模型實作是否合理；不預期 OLS 的理論擬合能力增加
Model C	經特徵選擇的部分原始特徵 + row sum	檢查 row sum 是否能在簡化模型中提供價值

三種模型必須使用相同的訓練集與測試集。若需要選擇特徵或調整超參數，請在訓練資料內進行交叉驗證。

評估時比較：

- 測試集 R^2：越高通常越好。
- 測試集 RMSE：越低越好。
- 測試集 MAE：越低越好。

如果 Model C 使用更少的特徵，卻能維持與 Model A 相近的測試集表現，那麼 row sum 就可能是有價值的特徵工程成果。

四、還有一件事必須優先確認：是否存在資料洩漏？

如果你的目標變數是由這 20 個特徵加總、加權加總，或經過某種公式計算而來，那麼 row sum 與目標變數高度相關就可能是預期中的結果。

例如，若目標變數本來就定義為：

$$Y \approx \sum_{j=1}^{20} X_j$$

那麼 $r = 0.91$ 並不一定代表你找到了一個很好的新特徵，也可能只是重新表達了目標變數的生成方式。

這不一定在所有情境下都是資料洩漏；關鍵在於預測當下，這些特徵是否真的可取得，以及目標變數的定義是否直接使用了它們。若 row sum 使用了預測時不應知道的資訊，就不能將其用於有效的預測模型。

五、我的結論

如果你目前的目標是完成多元線性回歸與特徵選擇的作業，我會保留 row sum 作為候選特徵，但不會直接把它加到全部 20 個原始特徵裡。

最有分析價值的方式，是比較「全部原始特徵」與「特徵選擇後的子集 + row sum」，再利用測試集驗證它是否能在減少特徵數量的同時維持預測能力。

我想先確認一個關鍵細節：**你的目標變數是怎麼產生的？**

- A. 由實際測量或觀察得到，與 20 個特徵分開記錄。
- B. 由這 20 個特徵透過某個公式計算而來。
- C. 不確定目標變數的產生方式。

這會直接影響我們應該如何解釋 0.91 的相關係數，以及 row sum 是否值得納入模型。

你說：

請比較以下 5 種特徵選擇方法的原理、優缺點與適用時機：
SelectKBest (f_regression)、RFE、SequentialFeatureSelector、Lasso、Permutation Importance。
另外請問：如果這 5 種方法選出來的特徵彼此不一致，代表什麼意思？該怎麼解讀？

ChatGPT 說：

這五種方法都可以用來做特徵選擇或評估特徵的重要性，但它們的**判斷依據其實不一樣**。因此，同一份資料用五種方法選出不同特徵，並不一定代表某種方法錯了，而可能是它們正在回答不同的問題。

以你目前的「多元線性回歸」作業為例，我會建議先掌握三個核心區別：

- **單變數關聯性**：某個特徵單獨與目標變數有多大關聯？
- **模型中的貢獻**：在其他特徵已經存在時，這個特徵是否還有幫助？
- **對預測的影響**：模型實際使用這個特徵時，預測表現會受到多大影響？

這三個問題不同，自然可能選出不同的特徵。

一、五種方法的原理比較

1. SelectKBest (`f_regression`)

Filter | 篩選法

原理： 分別檢驗每個特徵與連續目標變數之間的線性關聯，計算 F 統計量，再挑出分數最高的 K 個特徵。

優點

- 計算快速，容易理解。
- 不需要反覆訓練整個預測模型。
- 適合從大量特徵中先做初步篩選。

缺點

- 一次只看一個特徵，沒有考慮特徵之間的互補或重複資訊。
- 可能漏掉單獨關聯弱、合併後卻有價值的特徵。
- 必須自行決定 K，或透過交叉驗證選擇。

適用時機： 特徵數量較多、需要快速建立基準，或想了解哪些特徵各自與目標變數有線性關聯。

2. RFE（Recursive Feature Elimination）

Wrapper | 包裝法

原理： 先用指定模型訓練，依模型提供的特徵重要性（例如線性回歸係數）移除較不重要的特徵，再重新訓練，重複直到剩下指定數量。

優點

- 會考慮特徵一起進入模型後的表現。
- 可以搭配線性回歸等不同模型。
- 能直接產生指定數量的特徵子集。

缺點

- 需要多次訓練模型，速度通常比 SelectKBest 慢。
- 結果會受所選模型、特徵尺度及相關特徵影響。
- 一般 RFE 不會自動找出最佳特徵數量；可用 RFECV 搭配交叉驗證。

適用時機： 已經決定使用哪一種預測模型，希望針對該模型逐步刪除不必要的特徵。

3. SequentialFeatureSelector（SFS）

Wrapper | 包裝法

原理： 反覆比較不同特徵子集的交叉驗證分數，逐步加入或移除特徵。

- **Forward（前向選擇）：** 從空集合開始，每次加入能讓分數改善最多的特徵。
- **Backward（後向選擇）：** 從全部特徵開始，每次移除影響最小的特徵。

優點

- 直接依照預測模型的評估分數選特徵。
- 能考慮特徵組合，而不只是單一特徵的相關性。
- 可以指定想保留的特徵數量或使用自動停止條件。

缺點

- 需要大量重複訓練，計算成本可能很高。
- 屬於逐步搜尋，通常不會找到所有可能組合中的全域最佳解。
- 高度相關的特徵可能互相替代，導致選擇結果不穩定。

適用時機： 特徵數量中等，希望找到能讓特定模型預測表現良好的特徵組合。

4. Lasso（L1 正則化）

Embedded | 嵌入法

原理： 訓練線性回歸時，在誤差函數中加入係數絕對值總和的懲罰，促使部分係數縮小到零，藉此選出特徵。

$$\min_{\beta}\left[\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2+\lambda\sum_{j=1}^{p}|\beta_j|\right]$$

其中 λ 控制正則化強度；通常越大，越多係數會變成零。

優點

- 同時進行模型訓練與特徵選擇。
- 可以降低過度擬合的風險。
- 適合高維度資料，也能產生較精簡的模型。

缺點

- 特徵尺度差異大時，選擇結果可能不公平，因此通常要先標準化。
- 面對高度相關的特徵，可能只保留其中一個，且選誰可能隨資料變動。
- λ 不同，選出的特徵可能不同；Lasso 也可能因偏差而犧牲部分預測精度。

適用時機： 想讓線性回歸模型同時完成正則化與特徵篩選，尤其是特徵很多、希望模型更精簡時。

5. Permutation Importance（置換重要性）

Model inspection | 模型檢視

原理： 先訓練模型，再隨機打亂某一特徵的值，破壞該特徵與目標變數的原始對應關係，觀察模型評估分數下降多少。

例如，原本測試集 $R^2 = 0.85$，打亂某個特徵後降到 0.60，表示模型對該特徵有相當程度的依賴。

優點

- 不限於線性回歸，可用於許多不同模型。
- 直接衡量特徵對指定評估指標的影響。

- 可以在獨立測試集上計算，檢查模型對未見資料的依賴。

缺點

- 它本身不會自動訓練一個刪除該特徵後的新模型。
- 高度相關的特徵可能互相補位，使各自的置換重要性都偏低。
- 結果會受評估資料、模型及所選指標影響；置換還可能產生不符合真實資料分布的樣本。

適用時機： 模型訓練完成後，想了解模型實際依賴哪些特徵，或比較特徵對預測效能的影響。

二、五種方法快速對照表

比較項目	SelectKBest	RFE	SFS	Lasso	Permutation Importance
方法類型	Filter	Wrapper	Wrapper	Embedded	模型檢視
判斷依據	單一特徵的 F 分數	模型特徵重要性	特徵子集的 CV 分數	正則化後的係數	打亂特徵後的分數變化
考慮特徵組合	否	是	是	是	透過已訓練模型間接反映
需要反覆訓練	否	是	是	訓練一次或多次調參	通常不必重新訓練
能否直接產生子集	可以	可以	可以	可以	不會自動產生
主要用途	快速初篩	逐步刪除	搜尋特徵組合	稀疏化線性模型	解讀模型依賴性

注意：RFE、SFS 和 Lasso 的「考慮特徵組合」方式不同；Permutation Importance 則是檢查已訓練模型，而不是直接搜尋最佳特徵子集。

三、五種方法選出來的特徵不一致，代表什麼？

最重要的結論：特徵選擇結果不一致，不代表你的分析失敗。 它通常反映了特徵之間的關係、模型的特性，以及評估方式的差異。

情況 1：多個特徵高度相關，彼此可以替代

假設資料中有：

- X_1：每週運動時間
- X_2：每週運動次數

- X_3：每週運動消耗熱量

這三個特徵可能高度相關。

假設性的選擇結果

SelectKBest	Lasso	Permutation
選 X_1	選 X_2	三者個別影響偏低

這可能是因為三個特徵提供了大量重複資訊。只要模型保留其中一個，其他特徵的額外貢獻就可能不明顯。

該怎麼解讀？ 不要急著認定 X_1 一定比 X_2 重要。先檢查相關矩陣，再比較不同特徵組合的交叉驗證表現。

情況 2：單獨關聯很強，但加入模型後沒有額外幫助

SelectKBest 可能選到與目標變數高度相關的特徵，但 RFE 或 SFS 卻把它排除。

原因是 SelectKBest 分別看每個特徵；RFE 和 SFS 則會考慮其他特徵已經在模型中的情況。

例如，X_1 單獨就能預測 y，但 X_2 已經提供幾乎相同的資訊。因此，把 X_1 加進包含 X_2 的模型，可能無法再明顯改善預測。

該怎麼解讀？ 這個特徵可能有單獨的預測能力，但不一定有額外的預測價值。

情況 3：Lasso 選到的特徵與 RFE 不同

Lasso 會懲罰係數大小，並可能把部分係數壓到零；RFE 則依照模型提供的特徵重要性逐步刪除特徵。

當特徵彼此相關時，Lasso 可能保留其中一個，而 RFE 可能保留另一個。這不代表哪一種一定正確，而是兩種方法採取了不同的選擇策略。

該怎麼解讀？ 檢查特徵相關性、不同資料切分下的選擇穩定性，以及最後的測試集表現。

情況 4：Permutation Importance 的排序和其他方法不同

這很正常，因為 Permutation Importance 衡量的是：

> 在目前已訓練的模型中，打亂某個特徵會讓預測分數下降多少？

它不是在問「這個特徵與目標變數的相關性有多高」，也不是在問「這個特徵是否一定應該保留」。

當兩個特徵高度相關時，打亂其中一個，模型仍可能透過另一個特徵維持預測能力，因此兩者的重要性都可能不高。

該怎麼解讀？ 把 Permutation Importance 當成模型依賴性的證據，而不是特徵本身價值的絕對排名。

情況 5：不同方法在不同資料切分中，選擇結果也一直變動

這可能代表：

- 資料量不足，抽樣變動影響較大。
- 特徵高度相關，存在多個相近的替代方案。
- 某些特徵的預測貢獻很弱，選不選它對模型差異不大。
- 資料中有雜訊，或模型對訓練資料過度擬合。

該怎麼解讀？ 不要只看某一次切分的特徵名單。可以透過重複交叉驗證，統計每個特徵被選中的頻率，再比較各模型的預測表現。

四、實際上該怎麼分析？我建議你照這個順序做

1 **先做資料檢查**

檢查特徵與目標變數的關係、特徵間相關矩陣、缺失值與資料洩漏。若特徵尺度差異很大，Lasso 前要先標準化。

2 **用不同方法提出候選特徵**

可以先用 SelectKBest 快速初篩，再用 RFE、SFS、Lasso 找出候選子集。
Permutation Importance 則用來檢查已訓練模型的預測依賴性。

3 **公平比較預測表現**

比較使用全部特徵的模型與各種選擇方法產生的模型，使用相同的資料切分、相同的評估指標，例如 R^2、RMSE 和 MAE。

4 **檢查穩定性並決定最終模型**

在訓練資料內進行交叉驗證與特徵選擇，觀察特徵被選中的頻率。最後才用未參與選擇的測試集做一次最終評估。

五、如何決定該採用哪一種特徵選擇結果？

不一定要強迫五種方法選出相同的特徵。可以依照你的研究目標決定：

- **目標是預測準確度：** 優先看交叉驗證與測試集表現，而不是哪種方法選得最多。
- **目標是精簡模型：** 比較特徵數量、預測誤差與模型複雜度。
- **目標是解釋哪些因素與結果相關：** 同時檢查特徵相關性、係數方向、估計不確定性；不能把特徵重要性直接解讀成因果關係。
- **目標是找出穩定的特徵：** 觀察多次重複抽樣後的選擇頻率，而非只看一次結果。

還有一個很重要的原則：**特徵選擇必須在訓練資料內完成**。若先用整份資料挑選特徵，再切出測試集，測試集資訊就已經間接參與建模，可能使評估結果過度樂觀。

對你的多元線性回歸作業，我會把「全部特徵的線性回歸」當作基準，再比較 SelectKBest、RFE、SFS、Lasso 各自選出的特徵子集；最後用一致的測試集指標比較。Permutation Importance 則可以補充說明模型實際依賴哪些特徵。

報告中最值得寫的，不是五種方法是否選出相同名單，而是：為什麼名單不同、特徵間是否存在替代資訊，以及這些差異有沒有實際影響模型表現。

你說：

我要在報告中呈現多元線性回歸的結果，請問應該放哪些圖表最有說服力？
每種圖分別能說明什麼？另外評估指標應該報告哪些，
R^2 和 Adjusted R^2 的差別是什麼，什麼時候該看哪一個？

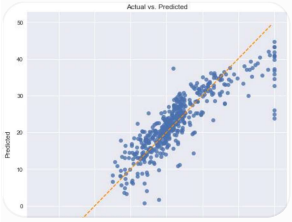
ChatGPT 說：

如果你要在 CRISP-DM 報告中呈現「多元線性回歸」的結果，我會建議不要只放一張預測結果圖和一個 R^2，而是用圖表依序回答四個問題：

1. **模型預測得準不準？**
2. **線性回歸的假設是否合理？**
3. **哪些特徵與目標變數有關？**
4. **加入或刪除特徵後，模型是否真的變好？**

對你的報告而言，最有說服力的組合是：**實際值 vs. 預測值散佈圖、殘差診斷圖、特徵係數圖，以及模型評估指標比較表**。如果你有比較不同特徵選擇方法，再加上模型效能比較圖表。

一、最值得放進報告的圖表



1. 實際值 vs. 預測值散佈圖（Actual vs. Predicted）

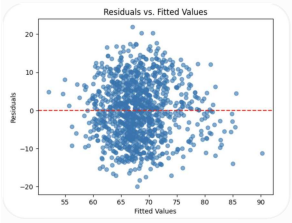
必放

怎麼畫： X 軸放真實目標值 y，Y 軸放模型預測值 $\hat{y}$，加上一條 $y = x$ 的 45° 參考線。

能說明什麼：

- 點越靠近參考線，預測越接近真實值。
- 若高數值區域的點普遍落在線下，代表模型可能低估高值。
- 若點呈現彎曲或其他系統性形狀，可能代表線性模型無法捕捉資料關係。

報告時注意： 優先使用未參與訓練的測試集預測結果，避免只呈現訓練集的漂亮表現。



2. 殘差 vs. 預測值圖（Residuals vs. Fitted）

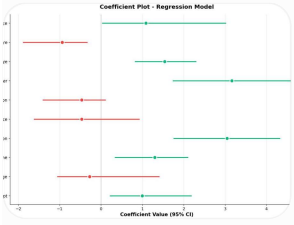
必放

怎麼畫： X 軸放預測值 $\hat{y}$，Y 軸放殘差 $e = y - \hat{y}$，加上 $e = 0$ 的水平線。

能說明什麼：

- 點在零線上下隨機分布：支持模型沒有明顯的系統性偏差。
- 漏斗形：可能存在異質變異，誤差大小會隨預測值改變。
- U 形或曲線：可能有非線性關係未被模型捕捉。
- 明顯的群聚：可能有不同子群、遺漏變數或資料結構。

這張圖比單看 R^2 更能幫你檢查線性回歸是否合理。注意，沒有明顯模式不等於所有假設都已成立。



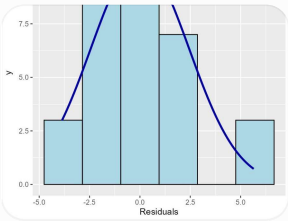
3. 回歸係數圖（Coefficient Plot）

怎麼畫： 每個特徵一列，X 軸放回歸係數；正值與負值分別顯示方向。如果可以，加入 95% 信賴區間。

能說明什麼：

- 正係數：控制模型中其他特徵後，該特徵增加與預測目標增加相關。
- 負係數：控制其他特徵後，該特徵增加與預測目標降低相關。
- 信賴區間若跨過零，代表該係數的不確定性可能較大；這要在適當的統計假設下解讀。

注意： 不同單位的原始係數不能直接比較大小。例如身高以公分計算、收入以元計算，係數尺度就不同。若想比較相對大小，可以另外呈現標準化係數，但要註明標準化方式。



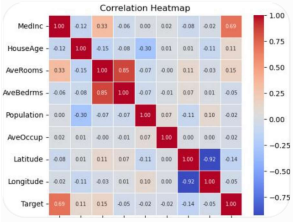
4. 殘差分布直方圖（Residual Histogram）

怎麼畫： 顯示殘差的分布，可加上零線或參考常態分布曲線。

能說明什麼：

- 殘差是否大致以零為中心。
- 是否偏斜、具有長尾，或有極端殘差。
- 是否可能有少數難以預測的樣本。

注意： 殘差看起來接近常態，不代表模型一定正確；常態性主要影響傳統迴歸推論中的檢定與信賴區間，而不是 R^2 的計算本身。



5. 特徵相關性熱圖（Correlation Heatmap）

怎麼畫： 對數值特徵與目標變數計算 Pearson 相關係數，使用色彩呈現正負相關與相關強度。

能說明什麼：

- 哪些特徵與目標變數有較強的單變數線性關聯。
- 哪些特徵彼此高度相關，可能出現多重共線性。
- 為什麼 SelectKBest 與其他特徵選擇方法可能得到不同結果。

注意： 相關係數不是因果關係，也不是多元回歸係數；一個特徵單獨與目標相關，不代表控制其他特徵後仍然有相同效果。

二、如果你比較五種特徵選擇方法，還應該加什麼？

6. 不同模型的評估指標比較表

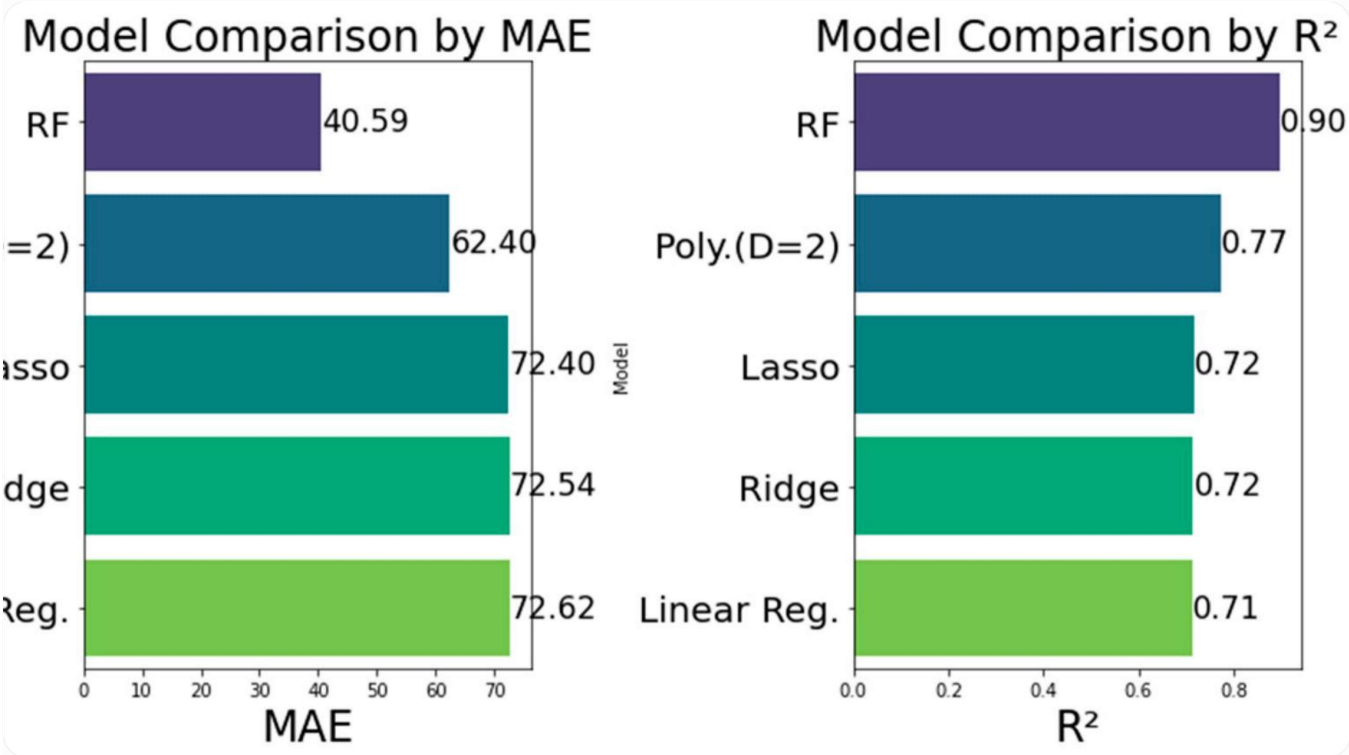
這張表通常是整份報告最重要的結果之一。你可以比較使用全部特徵、SelectKBest、RFE、SequentialFeatureSelector、Lasso 所得到的模型。

模型	特徵數量	Test R^2	Test RMSE	Test MAE
全部特徵	20	—	—	—
SelectKBest	待填	—	—	—
RFE	待填	—	—	—

SequentialFeatureSelector	待填	—	—	—
Lasso	待填	—	—	—

表格中的數值要由實際實驗取得，不要預先假設哪一種方法會最好。所有模型都應使用相同的測試集，且特徵選擇和調參只能使用訓練資料。

7. 模型效能比較圖



可以用長條圖比較不同模型的測試集 RMSE 或 MAE，也可以單獨畫一張比較測試集 R^2。

- **RMSE / MAE 越低越好**。
- R^2 **越高通常越好**，但測試集的 R^2 可能是負值。
- 若兩個模型的誤差非常接近，可以優先考慮特徵較少、較容易解釋的模型。

如果想同時呈現預測能力與模型簡潔性，可以另外畫一張散佈圖：X 軸放特徵數量，Y 軸放測試集 RMSE。這能讓讀者看出「少用多少特徵，付出了多少預測誤差」。

8. 選配：VIF 多重共線性診斷表

如果你的研究有 20 個數值特徵，且發現許多特徵彼此高度相關，建議加上 VIF（Variance Inflation Factor）表。

VIF 用來衡量某個特徵能被其他特徵解釋到什麼程度，協助辨識係數估計可能不穩定的問題。常見的 5 或 10 是經驗性警示門檻，並非絕對判定標準。

這張表特別適合用來解釋：為什麼模型的 R^2 很高，但某些迴歸係數的正負號或大小卻不穩定。

三、評估指標應該報告哪些？

我建議至少報告 R^2、RMSE、MAE。如果是傳統統計導向的迴歸報告，再加上 Adjusted R^2；如果比較不同特徵數量的模型，也很值得報告。

指標	意義	判讀方式
R^2	模型相對於以目標平均值作為預測基準，解釋了多少目標變異	越高通常越好；測試集可能為負
Adjusted R^2	對特徵數量進行調整的 R^2	同一資料集上，可比較不同複雜度的迴歸模型
RMSE	預測誤差平方的平均值開根號	越低越好；對大誤差較敏感
MAE	預測誤差絕對值的平均	越低越好；較容易直觀解釋
MSE（選配）	預測誤差平方的平均	越低越好；單位是目標單位的平方

1. R^2：模型解釋了多少變異？

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

其中：

- y_i：實際值
- $\hat{y}_i$：預測值
- $\bar{y}$：實際目標值的平均數

例如測試集 $R^2 = 0.80$，可以說模型相對於「一律預測測試集目標平均值」的基準，取得了 0.80 的決定係數。

但要注意，這**不等於每筆預測有 80% 的準確率**，也不代表模型一定能解釋因果關係。

2. RMSE：模型的誤差有多大？

$$RMSE = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}$$

假設目標變數是房價，單位為萬元，RMSE 為 10，代表誤差平方平均後開根號的大小是 10 萬元。

RMSE 對大誤差的懲罰較重，因此如果你特別在意少數預測錯得很離譜的案例，RMSE 很有用。

3. MAE：平均差多少？

$$MAE = \frac{1}{n}\sum_{i}|y_i - \hat{y}_i|$$

如果 MAE 是 7 萬元，可以解讀為預測與實際值的絕對差距平均為 7 萬元。

MAE 和 RMSE 都使用目標變數的原始單位，比 R^2 更容易直接向讀者說明誤差的實際大小。

四、R^2 和 Adjusted R^2 有什麼差別？

這是多元線性回歸報告中很重要的觀念，尤其你正在做特徵選擇。

先用直覺理解

假設你想預測學生的期末成績。

- 模型 A 使用 3 個特徵。
- 模型 B 使用 10 個特徵。

如果模型 B 多加了 7 個特徵，即使這些特徵沒什麼用，普通的訓練集 R^2 通常也不會降低。這是因為一般最小平方法可以讓新增特徵的係數為零，至少不會比原模型差。

因此，只看 R^2，可能會偏好越來越複雜的模型。

Adjusted R^2 就是為了考慮特徵數量而設計的調整指標。

數學上的差異

$$R^2 = 1 - \frac{SSE}{SST}$$

$$R^2_{\text{adj}} = 1 - (1 - R^2)\frac{n-1}{n-p-1}$$

其中：

- n：樣本數
- p：模型中的預測特徵數量，不包含截距
- SSE：殘差平方和
- SST：總平方和

Adjusted R^2 會依樣本數與特徵數量調整 R^2。在一般含截距的 OLS 模型中，它只有在新增特徵帶來足夠的改善時，才會上升。

什麼時候看哪一個？

看 R^2

- 想描述模型的解釋程度。
- 比較相同目標變數、相同資料集上的模型。
- 評估模型在訓練集或測試集的擬合表現。

若比較不同特徵數量的模型，不能只靠訓練集 R^2 判定誰最好。

看 Adjusted R^2

- 想比較同一資料集上、特徵數量不同的傳統線性回歸模型。
- 想知道新增特徵是否值得增加模型複雜度。
- 想在報告中呈現模型的擬合程度與特徵數量之間的權衡。

它不是通用的特徵選擇演算法，也不能保證測試集預測效果更好。

特別注意：Adjusted R^2 並不是專門用來評估新資料預測能力的指標。若你的主要目標是預測，仍應以交叉驗證或獨立測試集上的 R^2、RMSE、MAE 作為主要依據。

五、給你的報告一個實用的配置建議

如果篇幅有限，我會把圖表安排成以下順序：

報告順序	圖表 / 表格	主要目的
1	目標變數分布圖、相關性熱圖	了解資料特性與初步關聯
2	特徵選擇結果表	說明各方法保留哪些特徵
3	模型效能比較表	比較 R^2、Adjusted R^2、RMSE、MAE
4	實際值 vs. 預測值圖	呈現預測結果是否貼近真實值

5	殘差 vs. 預測值圖	檢查非線性、異質變異及系統性誤差
6	回歸係數圖	解釋各特徵的方向與估計大小
7	殘差分布圖、VIF 表	作為額外的模型診斷

若你的作業重點是 **CRISP-DM 的 Modeling 與 Evaluation**，前三項和第四、第五項最值得優先完成；係數圖與 VIF 則可以強化分析深度。

最後，請記住一個原則：**好的回歸報告不只是證明 R^2 很高，而是同時說明預測誤差、模型假設、特徵的解釋方式，以及模型在未見資料上的表現。**